



ЦЕНТР НЕПРЕРЫВНОГО ОБРАЗОВАНИЯ
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

Прототип Feature Store для корпоративной платформы машинного обучения

Шитова Анастасия, группа DE-1

Описание исследования

1 Цель исследования: построить архитектуру Feature Store и реализовать её в коде


2 Задачи исследования:

- выбрать компоненты Feature Store (БД, хранилище, оркестратор);
- составить сценарии использования Feature Store;
- реализовать в коде;
- получить исходные данные для тестирования решения;
- развернуть необходимые образы в Docker;
- протестировать путь данных в получившейся системе.

3 Объект исследования: архитектура Feature Store

4 Предмет исследования: способы построения Feature Store

Компоненты Feature Store



Исходные данные

Данные веб-аналитики (посещения страниц, информация о сессиях)

Сгенерированы python-скриптом и загружены в БД PostgreSQL (слой сырых данных)

Признаки, полученные из данных:

- Посещаемость по датам
- Количество просмотров страниц по датам
- Показатель отказов (Bounce Rate) по каналам привлечения трафика
- Показатель средней продолжительности сессии по каналам привлечения трафика

Этапы обработки данных

- Сырые данные хранятся в БД PostgreSQL
- Оркестратор обработки данных – Airflow
- Данные выгружаются из БД PostgreSQL с рассчитанными признаками
- Результаты выгрузки трансформируются в файлы parquet и выгружаются в Minio
- В Minio данные хранятся в бакете и разделены по названию признака, версии и дате выгрузки для упрощения запросов
- Также результаты выгрузки запросом переносятся в таблицы ClickHouse (таблицы предварительно очищаются, хранится только последний срез данных)
- В БД PostgreSQL ведётся реестр признаков (из него, например, берётся последняя версия признака для использования в обработке данных)

Результаты и выводы

- Успешно разработана и реализована в коде выбранная архитектура Feature Store
- На примере данного исследования можно заметить, что реализация собственной версии Feature Store возможна и не слишком трудозатратна
- Более того, собственную реализацию гораздо проще приспособить и настроить под требования бизнеса: выбрать и собрать необходимые компоненты, реализовать логику обработки данных
- В целом, использование Feature Store может помочь организовать работу с признаками: избежать дублирования признаков, сделать более прозрачным механизм расчёта признаков и упростить доступ к уже рассчитанным признакам

Спасибо за внимание!